

Plan de estudio de 5 semanas


Databricks Certified Data Engineer Associate

Basado en la guía oficial del examen, versión vigente al 4 de mayo de 2026.

El examen en números

Preguntas	45 preguntas de opción múltiple con puntaje (puede haber ítems extra sin puntaje, no identificados)
Duración	90 minutos (unos 2 minutos por pregunta)
Costo	USD 200 más impuestos locales
Modalidad	Online o en centro de examen. No se permite ningún material de apoyo
Validez	2 años; para recertificar hay que rendir el examen vigente
Requisitos	Ninguno obligatorio. Se recomiendan el curso y 6 meses de práctica en Databricks

Peso de cada sección



Las secciones 2, 3, 4 y 7 suman el 74% del examen: ahí conviene invertir más práctica.

Cómo está organizado el plan

- **Dedicación estimada:** 8 a 10 horas por semana (aprox. 1,5 h por día de lunes a sábado, con un día de descanso). Si tenés menos tiempo, estirá el plan a 7 u 8 semanas.
- **Orden:** se agrupan secciones afines. Semana 1: plataforma y gobernanza. Semana 2: ingesta. Semana 3: transformación. Semana 4: Jobs y CI/CD. Semana 5: monitoreo, optimización y simulacros.
- **Regla 70/30:** en cada sesión, 30% teoría (documentación y cursos) y 70% práctica en un workspace real.
- **Repaso espaciado:** el día 6 de cada semana incluye repaso de lo anterior; no avances sin hacerlo.

Semana 1 - Plataforma y Gobernanza (secciones 1 y 7: 21%)

Objetivo: entender la arquitectura, elegir el compute correcto y dominar Unity Catalog y sus permisos.

Día	Tema	Qué hacer
1	Arquitectura y Delta Lake	Data Intelligence Platform: plano de control y de datos, lakehouse, arquitectura medallion. Delta Lake: transacciones ACID, time travel, historial (DESCRIBE HISTORY, RESTORE).
2	Compute	All-purpose vs job clusters vs SQL warehouses vs serverless. Características, limitaciones y modelo de costos. Armá una tabla de 'caso de uso -> compute'.
3	Unity Catalog: objetos	Jerarquía metastore, catalog, schema, tabla, volumen. Tablas managed vs external: crear, modificar, borrar (qué pasa con los datos) y convertir entre ambas.
4	Permisos	GRANT, REVOKE y DENY sobre usuarios, grupos y service principals. Herencia de privilegios en la jerarquía. Practicá por UI y por SQL.
5	Seguridad a nivel fila/columna	Row filters y column masks según grupo. Políticas ABAC de Unity Catalog para filtrado y enmascarado centralizado.
6	Repaso	Hacé un cuadro comparativo (managed vs external, tipos de compute). Respondé 15 a 20 preguntas de práctica de las secciones 1 y 7.
7	Descanso	Opcional: leer la guía de gobernanza en Databricks Academy.

Puntos que suelen preguntarse

- Cuál compute conviene para ad hoc SQL con muchos usuarios vs ETL programado.
- Qué ocurre con los archivos al hacer DROP de una tabla managed vs external.
- A qué nivel de la jerarquía conviene otorgar un privilegio para que se herede.

Semana 2 - Ingesta y carga de datos (sección 2: 21%)

Objetivo: elegir la herramienta de ingesta adecuada para cada escenario y saber configurarla.

Día	Tema	Qué hacer
1	Patrones de ingesta	Batch, streaming e incremental: cuándo usar cada uno y sus compromisos de latencia, costo y complejidad. Carga desde archivos locales.
2	COPY INTO	Carga incremental e idempotente desde ADLS/S3/GCS hacia tablas de Unity Catalog. Formatos, opciones (FORMAT_OPTIONS, COPY_OPTIONS) y comportamiento ante archivos ya cargados.
3	Auto Loader	Formato cloudFiles, modos directory listing vs file notification, checkpoint, inferencia y evolución de esquema, rescued data column.
4	Lakeflow Connect	Conectores standard vs managed, conectores de partners. Armá una matriz de decisión: volumen, frecuencia, tipo de dato, gobernanza.
5	JDBC/ODBC, REST y semi-estructurados	Leer desde bases por JDBC y APIs REST en notebooks, orquestado con Jobs. Ingesta de JSON y datos anidados a tablas Delta.
6	Laboratorio	Ingestá el mismo dataset con COPY INTO y con Auto Loader, y comparalos. Repasá las secciones 1 y 7.
7	Descanso	

Puntos que suelen preguntarse

- COPY INTO vs Auto Loader: cuándo uno es más adecuado que el otro.
- Qué pasa cuando llega una columna nueva a un origen (schema evolution).
- Comportamiento de los logs de auditoría de Databricks (formato JSON, latencia, sobreescritura): aparece en las preguntas de muestra.

Semana 3 - Transformación y modelado (sección 3: 22%)

Objetivo: escribir transformaciones en PySpark y SQL, construir capas silver y gold, y conocer el tuning básico.

Día	Tema	Qué hacer
1	Bronce a plata	Leer tablas bronce, tratar nulos, estandarizar tipos (cast) y escribir tablas silver en Unity Catalog.
2	Joins y uniones	Inner, left, broadcast, múltiples claves, cross join; union vs union all (con y sin eliminación de duplicados).
3	Columnas y filas	Agregar, eliminar, dividir y renombrar columnas; filtros; explode de arrays. Hacelo en PySpark y en SQL.
4	Deduplicación y agregaciones	dropDuplicates y ventanas (row_number). count, approx_count_distinct, mean y summary.
5	Tuning y capa gold	spark.sql.shuffle.partitions, spark.default.parallelism, memoria de executor/driver, autoBroadcastJoinThreshold. Diferencias entre views, materialized views, streaming tables y tablas. Controles de calidad y validación.
6	Laboratorio integrador	Armá un pipeline bronce, plata, gold con validaciones de calidad. Simulacro de 20 preguntas de la sección 3.
7	Descanso	

Puntos que suelen preguntarse

- Cuándo usar un broadcast join y qué controla autoBroadcastJoinThreshold.
- Diferencia entre view, materialized view y streaming table para consumo de BI.
- Elegir entre union y union all según se quieran o no eliminar duplicados.

Semana 4 - Lakeflow Jobs y CI/CD (secciones 4 y 5: 26%)

Objetivo: orquestar pipelines y promover el mismo código entre dev, test y prod.

Día	Tema	Qué hacer
1	Tareas y DAG	Tipos de tarea: notebook, SQL query, dashboard y pipeline. Dependencias entre tareas en el grafo (DAG).
2	Control de flujo	Reintentos, tareas condicionales (branching) y bucles (for each). Probá cada uno en un job real.
3	Triggers y schedules	Programado, file arrival y table update. Cuándo conviene un trigger por tiempo vs uno basado en datos.
4	Git Folders	Crear y cambiar de ramas, commit, push y pull requests desde la UI del workspace.
5	Bundles y CLI	Declarative Automation Bundles (antes Databricks Asset Bundles): estructura, variables, overrides y targets dev/test/prod. CLI: validate, deploy, run.
6	Laboratorio	Creá un bundle con un job y desplégalo en dos targets. Simulacro de 20 preguntas de secciones 4 y 5.
7	Descanso	

Puntos que suelen preguntarse

- Qué trigger usar si el job debe correr apenas lleguen archivos nuevos.
- Cómo parametrizar un bundle por entorno sin duplicar código.
- Flujo de CI/CD con Bundles y Git: es la respuesta correcta de la pregunta de muestra 5.

Semana 5 - Monitoreo, optimización y simulacros (sección 6: 10% + repaso)

Objetivo: diagnosticar problemas de rendimiento y llegar al examen con práctica cronometrada.

Día	Tema	Qué hacer
1	Monitoreo de jobs	Historial de ejecuciones para comparar contra tiempos base, estados, grafo de tareas para detectar bloqueos y tasas de fallo.
2	Spark UI	Detectar data skew, shuffle y disk spilling con las métricas por stage (min, mediana, max de shuffle read). AQE y manejo de skew.
3	Liquid Clustering y diagnóstico	Liquid Clustering y predictive optimization. Fallas de arranque de cluster, conflictos de librerías y errores de memoria (OOM).
4	Simulacro 1	45 preguntas en 90 minutos, sin ayudas y en un lugar tranquilo.
5	Análisis de errores	Por cada pregunta fallada, anotó la sección y el concepto. Repasó las 2 secciones más débiles con práctica.
6	Simulacro 2 y repaso	Segundo simulacro. Repaso ligero de tus apuntes y cuadros comparativos.
7	Descanso previo	Dormí bien. Nada de contenido nuevo.

Puntos que suelen preguntarse

- Cómo se ve el skew en la Spark UI y por qué agregar más executors no lo resuelve.
- Qué señales indican spilling a disco y cómo se mitiga.
- Para qué sirve Liquid Clustering y qué automatiza predictive optimization.

Seguimiento de avance

Puntuá tu confianza de 1 (no lo sé) a 5 (lo domino) antes y después de cada semana. Apuntá a 4 o más en todas las secciones antes del examen.

Sección	Peso	Semana	Antes	Después	Simulacro
1. Plataforma Databricks	6%	1			
2. Ingesta y carga	21%	2			
3. Transformación y modelado	22%	3			
4. Lakeflow Jobs	16%	4			
5. CI/CD	10%	4			
6. Troubleshooting y optimización	10%	5			
7. Gobernanza y seguridad	15%	1			

Recursos recomendados (de la guía oficial)

- **Instructor-led:** Data Engineering with Databricks.
- **Databricks Academy (autoguiados):** Data Ingestion with Lakeflow Connect; Deploy Workloads with Lakeflow Jobs; DevOps Essentials for Data Engineering; Data Interoperability with Unity Catalog; Build Data Pipelines with Lakeflow Spark Declarative Pipelines; Get Started with Data Governance on Databricks.
- **Práctica:** un workspace de Databricks propio o la edición gratuita (Free Edition). Verificá qué funciones están disponibles, ya que algunas de CI/CD, conectores o compute pueden estar limitadas.
- **Documentación oficial** de Databricks para cada punto del esquema del examen.

Consejos para el día del examen

- Gestioná el tiempo: unos 2 minutos por pregunta. Marcá las dudosas y volvé al final.
- Descartá primero las opciones claramente incorrectas; en las de escenario, buscá la palabra clave (skew, incremental, gobernanza, costo).
- Si rendís online, probá la conexión, la cámara y el entorno con anticipación; no se permiten materiales de apoyo.
- Las preguntas de muestra de la guía son de versiones anteriores: sirven para ver el estilo, no como banco de preguntas.
- La guía no indica el puntaje mínimo de aprobación: consultalo en la página oficial del examen.

Fuente: Databricks Exam Guide - Data Engineer Associate (mayo 2026). Verificá siempre la versión más reciente antes de rendir, ya que Databricks puede actualizar el temario.